



Escola Secundária da Maia
Projeto Aqualogic
Física 12^º ano

Filipe Rodrigues
Gonçalo Couto
Luís Tavares
Luís Tavares

2025/2026

Introdução

A atividade das glândulas sudoríparas aumenta durante a exposição a temperaturas elevadas e em períodos de atividade intensa. A desidratação provoca efeitos adversos, como queda de pressão arterial, obstipação, disfunção renal, câibras, perda de rendimento desportivo e risco de arritmias em idosos. Por outro lado, a monitorização dos níveis de perda de água por sudorese permitem prevenir défices cognitivos associados à desidratação e adaptar o ambiente escolar e profissional para melhorar o desempenho dos estudantes e trabalhadores. Os sensores de atividade das glândulas sudoríparas poderão vir a ser integrados na próxima geração de tecnologias *wearable*, de modo a identificar défices hídricos, classificar a causa da desidratação com base noutros sensores (temperatura, frequência cardíaca) e alertar o utilizador. Partindo do princípio físico de que os eletrólitos da água reduzem a resistividade elétrica dos tecidos cutâneos e apresentam bandas de absorção próximas do infravermelho, propomos uma solução multimodal para medir o suor que combina um sensor elétrico de resposta galvânica da pele (GSR) com um sensor ótico (LED e fotodetector de 940 nm). Os dados serão transmitidos para uma aplicação que permite a visualização dos dados e reunir feedback para treinar continuamente um modelo de inteligência artificial, cujo principal objetivo é classificar binariamente perdas de água anómalas.

The activity of the sweat glands increases during exposure to high temperatures and periods of intense activity. Dehydration causes adverse effects such as a drop in blood pressure, constipation, renal dysfunction, cramps, reduced athletic performance and a risk of arrhythmias in older adults. On the other hand, monitoring the levels of water loss through sweating can prevent cognitive deficits associated with dehydration and make it possible to adapt school and workplace environments to improve the performance of students and workers. Sweat-activity sensors could be integrated into the next generation of wearable technologies to identify hydration deficits, classify the cause of dehydration based on other sensors (temperature, heart rate) and alert the user. Based on the physical principle that electrolytes in water reduce the electrical resistivity of skin tissues and exhibit absorption bands near the infrared, we propose a multimodal solution to measure sweat that combines an electrical sensor for galvanic skin response (GSR) with an optical sensor (LED and 940 nm photodetector). The data will be transmitted to an application that enables data visualization and collects feedback to continuously train an artificial intelligence model whose primary objective is to perform a binary classification of anomalous water losses.

Objetivos


- Calibrar um sensor de resposta galvânica da pele (GSR) e um sensor ótico para classificar binariamente quando um indivíduo está em estado de perda de água elevada, usando como referência a taxa relativa de perda de massa corporal medida por gravimetria
- Desenvolver a aplicação móvel

Participantes


4 voluntários saudáveis, com 17 anos, do sexo masculino.

Instrumentação

- Balança digital: gravimetria
- Arduino Uno
- Grove GSR: mede a resistência da pele
- Placa de expansão para sensores Grove
- Fotodíodo de 940 nm
- LED de 940 nm, a 100 mW
- Resistência de 1 M Ω e de 220 Ω
- Condensador cerâmico de 10 pF: contribui para a estabilidade da medição do fotodíodo
- Amplificador operacional LM358P: utilizado como amplificador de transimpedância; converte a corrente do fotodíodo em tensão proporcional



Circuito A - Ligação de um fotodíodo e de um LED de 940 nm (imagem produzida a partir do Tinkercad Circuits)



Circuito B - Ligação do sensor Grove GSR através de uma placa de extensão

```
void setup() {
  Serial.begin(115200);
  pinMode(8, OUTPUT);
  //Ligar o LED IR
  digitalWrite(8, HIGH);
}

void loop() {
  //Ler o valor do sensor GSR
  int a0 = analogRead(A0);
  //Ler o valor do fotodiodo
  int a1 = analogRead(A1);

  //Imprimir os valores para análise
  Serial.print(a0);
  Serial.print(",");
  Serial.println(a1);

  delay(100);
}
```

Programação em C++

Condições experimentais

- **Repouso:** o participante permanece sentado durante 20 minutos, à temperatura ambiente.
- **Exercício leve:** o participante efetua uma caminhada rápida durante 20 minutos, à temperatura ambiente.
- **Exercício intenso:** o participante corre a velocidades moderadas durante 20 minutos, à temperatura ambiente.

Procedimento

1. Medir m_0
2. Colocar o sensor GSR no dedo indicador e no dedo anelar e executar o exercício. Evitar manter o sensor ligado durante mais do que 1 minuto para evitar sobreaquecimento.

3. Calcular a resistência média, de acordo com a fórmula derivada pela regra do divisor de tensão, já que a pele está ligada em série com uma resistência de 10 kΩ no sensor.

$$R_{\text{instantânea}}(\Omega) = \frac{10000(1024+2U)}{U_0 - U}, \text{ em que } U_0 \text{ é o valor da tensão nas unidades do Arduino (1-1024).}$$

$$\text{Assim, } R_{\text{média}} = \frac{1}{N} \sum_{i=0}^N R_{\text{instantânea}}, \text{ onde } N = f \times \Delta t = 100.$$

4. Medir m_f e calcular a taxa temporal média de perda de massa

$$\text{Taxa (\% por h}^{-1}\text{)} = \frac{-\Delta m(\%) }{\Delta t} = \frac{m_0 - m_f}{m_0 \times \Delta t} \times 100, \text{ em percentagem por hora}$$

5. Medir a absorbância ótica relativa da pele a 940 nm, pela lei de Lambert-Beer:

$$A = -\log_{10}\left(\frac{I}{I_0}\right) = -\log_{10}\left(\frac{U - U_{\text{escuro}}}{U_{\text{referência}} - U_{\text{escuro}}}\right), \text{ onde } U \text{ é a tensão convertida pelo Arduino ADC (1-1023), } U_{\text{escuro}} \text{ é a tensão convertida sem iluminação e } U_{\text{referência}} \text{ é a tensão convertida com a pele seca.}$$

6. Determinar o rótulo da sessão (1, a taxa temporal média de perda de massa for mais elevada do que o limiar definido, ou, caso contrário, 0)

Resultados

Condições experimentais	Perda de água (% por h ⁻¹)	R _{média} (kΩ), U ₀ = 501	A _{média} (adimensional)	Rótulo da sessão
Exercício intenso durante 20 minutos	0.13	23	0.0	1 em todas as sessões
Exercício moderado durante 20 minutos	0.04	51	0.0	0 em todas as sessões
Repouso durante 20 minutos	0.00	118	0.0	0 em todas as sessões

Nota: Estabelecemos como limiar de desidratação uma taxa de 0.10% da massa corporal.

Embora a resistência da pele se relacione inequivocamente com a taxa de perda de massa corporal nos 4 voluntários, não foi possível confirmar o efeito da sudorese na variação na absorbância ótica da pele do comprimento de onda de 940 nanómetros, devido a limitações na sensibilidade do protótipo utilizado.

O nosso modelo de classificação binária baseado em limiar calculou o limiar ótimo de desidratação como sendo igual a 53,3 nas unidades do sinal do sensor GSR, com divisão treino-teste de 75%-25%. Escolhemos esse limiar, que corresponde a uma resistência de pele de cerca de 25,3 kΩ, porque é o parâmetro que minimiza o erro na classificação (0-1 loss) no nosso conjunto, ou seja, separa perfeitamente (com erro de 0%) as sessões com perda de água superior a 0.10% da massa corporal das sessões com perda de água inferior a ou igual a 0.10%.

```

# Definição da função de perda
# Recebe:
# - limiar: valor do threshold a testar
# - resistencia_pele: array com valores contínuos da resistência da pele
# - rotulo_sessao: array com rótulos binários da sessão (0 ou 1)
# Retorna:
# - média de erros de classificação (0-1 loss)
def perda(limiar, resistencia_pele, rotulo_sessao):
    # Predição: 1 se acima do limiar, 0 caso contrário
    previsao = (resistencia_pele <= limiar).astype(int)
    # Retorna a proporção de previsões incorretas
    return np.mean(previsao != rotulo_sessao)

# Chamada ao otimizador de limite
# - bounds: limites de busca (mínimo e máximo da resistência da pele)
# - method='bounded': busca eficiente em intervalo fechado
resultado = minimize_scalar(
    perda,
    args=(resistencia_pele, rotulo_sessao),
    bounds=(resistencia_pele.min(), resistencia_pele.max()),
    method='bounded'
)

# Limite ótimo encontrado
melhor_limiar = resultado.x
# Erro correspondente a esse limiar
melhor_erro = resultado.fun

print("Melhor limiar:", melhor_limiar)
print("Erro de classificação:", melhor_erro)

```

Figura 3: Descrição do modelo de *machine learning*




Figura 4: Gráfico ilustrativo do limiar de desidratação

Conclusão

Assim, os resultados são promissores. Num estudo piloto com 4 indivíduos, confirmamos empiricamente contra a gravimetria que a presença de eletrólitos no suor reduz a resistividade cutânea, pelo que existe um limiar de resistência que distingue estados de perda hídrica elevada. Contudo, para aplicar este limiar em contexto real, recomendamos recalibrar com maior diversidade de sujeitos e fatores ambientais.